

Chapter 1 计算机视觉、语音及多媒体信息处理

D

Chapter 2 计算机语言学、机器翻译 及自然语言理解

Chapter 3 仿脑计算理论与仿脑计算机

Chapter 4 智能信息处理

Chapter 5 虚拟现实，增强现实，虚拟环境

Chapter 6 机器学习

得到的的 DF

6.1 ANN, 人工神经网络

的 55 得到的的

ANN 的实质是通过已知的两个空间的一对子空间，寻找两个空间的映射关系，希望通过局部性质对整体有所刻画。

6.1.1 基础 1-凸优化

概念

极大似然估计

$$\begin{aligned} \min -L(\mu, \sigma) \\ \sigma \geq 0 \end{aligned} \tag{6.1}$$

最小二乘

$$\min f_0(x) = |\mathbf{Ax} - \mathbf{b}|^2 \tag{6.2}$$

where $\mathbf{A}_{n \times k}$, $\mathbf{b} \in \mathbb{R}^n$, for $\mathbf{x} \in \mathbb{R}^k$.

凸优化局部最优 = 全局最优

$$\begin{aligned} \min f_0(x) \\ f_i(x) \leq b_i, i = 1, \dots, m. \end{aligned} \tag{6.3}$$

$$\begin{aligned}
& \forall x_1, x_2 \in \Omega, \lambda \in (0, 1) \\
& \text{convex set} : \lambda x_1 + (1 - \lambda)x_2 \in \Omega \\
& \text{convex function} : f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2)
\end{aligned} \tag{6.4}$$

上境图是凸集 = 凸函数

凸组合 (重心):

$$S = w^i x_i, \text{ where } \sum w^i = 1 \tag{6.5}$$

凸包: x_i 的全部凸组合

凸闭包: f 的凸闭包的上境图, 是 f 的上境图的凸包。

Jensen 不等式: 对于凸函数 f , 有:

$$\sum w_i f(x_i) \geq f\left(\sum w_i x_i\right) \tag{6.6}$$

大部分不等式来自于 $x^2 \geq 0$, 或者 Jensen 不等式, 如:

$$\left. \begin{aligned} f &= -\ln(x) \\ w_i &\equiv \frac{1}{n} \end{aligned} \right\} \Rightarrow \left(\prod_{i=1}^n a_i \right)^{\frac{1}{n}} \leq \frac{\sum_{i=1}^n a_i}{n} \tag{6.7}$$

$$\left. \begin{aligned} f &= x^2 \\ x_i &= \frac{a_i}{b_i} \\ w_i &= \frac{b_i^2}{\sum b_i^2} \end{aligned} \right\} \Rightarrow \sum a_i^2 \sum b_i^2 \geq \left(\sum a_i b_i \right)^2 \tag{6.8}$$

性质

凸集性质:

凸集交集是凸集;

凸集的线性映射是凸集;

平行光源投影 (到任意平面上) 保持凸集;

点光源投影 (集合所有元素都除以同一个元素) 保持凸集, $\Omega_{\hat{n}} = \{x_i/x_n | x_i \in \Omega\}$;

点光源投影 (椎体) 保持凸集, $\{tx_i | x_i \in \Omega\}$;

凸集合边界可微, 则边界切平面是凸集的支撑平面;

凸集边界二阶可微, 则边界点曲率向量指向集合内部, 曲率向量是加速度方向或受力方向;

凸函数性质:

固定凸函数某些变量仍然是凸函数;

凸函数的非负线性组合是凸函数;

凸函数一阶可微, 则一阶近似不大于函数本身, $f(x) \geq f(x_0) + (\nabla f(x_0))^T \cdot (x - x_0)$;

凸函数二阶可微, 则 Hessian 阵半正定;

凸函数 $f(x_1, \dots, x_n)$, 有 $g(x_i) = \inf$ 是凸函数;

升维锥体保持凸性 $f: \mathbb{R}^n \mapsto \mathbb{R} \Rightarrow g(x, t) = tf(x/t): \mathbb{R}^{n+1} \mapsto \mathbb{R}$;

凸集分离定理:

\mathbb{R}^n 中两不相交非空凸集 C 和 D, 存在 $a \in \mathbb{R}^n, b \in \mathbb{R}$, 使得 $a^T x_C \leq b$ & $a^T x_D \geq b$, 几何意义是两个凸集在超平面 $a^T x = b$ 两侧, 其中 a 是超平面的法向量。超平面是 n 维空间中的 n-1 维平面。

6.1.2 基础 2-对偶问题

共轭函数

任意函数 f 的共轭函数: $f^*(y) = \sup(y^T x - f(x))$, 右边括号里是勒让德变换, 相当于在找从函数到超平面 $y^T x$ 的距离最大值, 函数返回从曲率等于超平面的 f(x) 沿着 y 的方向到超平面的最大值。

性质: f^* 是凸函数;

若 g 是 f 的凸闭包, $g^* = f^*$;

f 是凸函数时有 $f^{**} = f$;

$f(x) + f^*(y) \geq x^T y$;

f 是凸函数可微时, $f^*(y) = \nabla f(x)x - f(x)$;

$g(x) = f(Ax + b) \Rightarrow g^*(y) = f^*(A^{-T}y) - b^T A^{-T}y$;

$f(u, v) = f_1(u) + f_2(v) \Rightarrow f^*(w, z) = f_1^*(w) + f_2^*(z)$;

如:

$$\begin{aligned}
 f(x) &= x \ln x \Rightarrow \\
 f^*(y) &= \sup_x (yx - x \ln x) \\
 \frac{d(yx - x \ln x)}{dx} &= 0 \Rightarrow x^* = e^{y-1} \\
 \therefore f^*(y) &= ye^{y-1} - e^{y-1}(y-1) = e^{y-1}
 \end{aligned} \tag{6.9}$$

拉格朗日对偶函数

对于 \mathbb{R} 上的优化问题:

$$\begin{aligned} \min & f_0(x) \\ & f_i(x) \leq 0 \\ & h_i(x) = 0 \end{aligned} \quad (6.10)$$

优化点 x^* , 最优值 p^* ;

拉格朗日量 $\mathbb{R}^{n+m+p} \mapsto \mathbb{R}$

$$L(x, \lambda, v) = f_0(x) + \sum \lambda_i f_i(x) + \sum v_i h_i(x) \quad (6.11)$$

取 L 的下确界, 定义拉格朗日对偶函数

$$g(\lambda, v) = \inf_x L(x, \lambda, v) \quad (6.12)$$

对于 $\lambda \geq 0$ 有 $g(\lambda, v) \leq p^*$, 对偶函数能提供下界, 因此希望最大化 g 。对偶问题的最大值点 (λ^*, v^*) , 最大值 d^* 。

例子 1:

$$\begin{aligned} & \min c^T x \\ & \text{s.t. : } \begin{cases} x_i \geq 0 \Rightarrow -x_i \leq 0 \\ A^T x = b \end{cases} \\ \Rightarrow L &= C^T x - \lambda^T x + v^T (A^T x - b) \\ &= (C^T - \lambda^T + v^T A^T) x - v^T b \\ g(\lambda, v) &= \begin{cases} -\infty \\ -v^T b, C^T - \lambda^T + v^T A^T = 0 \end{cases} \\ \therefore \min & v^T b \\ \text{s.t. : } & \lambda \geq 0 \\ & C^T - \lambda^T + v^T A^T = 0 \end{aligned} \quad (6.13)$$

限制条件是线性时:

$$\begin{aligned}
 g &= \inf_x [f_0(x) + \lambda^T(Ax - b) + v^T(Cx - d)] \\
 &= -b^T\lambda - d^Tv + \inf_x [(A^T\lambda + C^Tv)^T x + f_0(x)] \\
 &= -b^T\lambda - d^Tv - f^*(-a^t\lambda - c^tv)
 \end{aligned} \tag{6.14}$$

例子 2, 最小化向量范数:

$$\min |x|, \text{ where } Ax = b \tag{6.15}$$

$$f^*(y) = \sup_x (\lambda^T x - |x|) = \begin{cases} 0, & |y| \leq 1 \\ +\infty, & |y| > 1 \end{cases} \tag{6.16}$$

$$\begin{aligned}
 g &= \inf_x [|x| + \lambda^T(Ax - b)] \\
 &= -b^T\lambda + \sup_x (-A^T x - |x|) \\
 &\therefore \max -b^T\lambda \\
 &|A^T\lambda| \leq 1
 \end{aligned} \tag{6.17}$$

例子 3, 最大熵:

$$\begin{aligned}
 &\max -\sum x_i \ln x_i \\
 &Ax \leq b \\
 &1^T x = 1
 \end{aligned} \tag{6.18}$$

$$\begin{aligned}
 y^* &= \sum e^{y_i - 1} \Rightarrow \\
 g &= \inf_x \left[\sum x_i \ln x_i + \lambda^T(Ax - b) + v^T(x - 1) \right] \\
 &= -b^T\lambda - v + \sup_x \left(-\lambda A^T x - vx - \sum x_i \ln x_i \right) \\
 &= -b^T\lambda - v - \sum e^{-\lambda^T A - v^T - 1} \\
 &\therefore \max g \\
 &\lambda \geq 0
 \end{aligned} \tag{6.19}$$

对偶性

弱对偶性: $d^* \leq p^*$

强对偶性: $d^* = p^*$

slater 条件, 对于凸优化问题, 如果存在取到不等号的点, 就满足强对偶性条。如线性规划、最小

二乘、最大熵问题都满足。

凸优化求解 (KKT)

$$\begin{aligned}
 f_i(x^*) &\leq 0 \\
 h_i(x^*) &= 0 \\
 \lambda_i^* &\geq 0 \\
 \lambda_i^* f_i(x^*) &= 0 \\
 \nabla_x L(x^*, \lambda^*, v^*) &= 0
 \end{aligned} \tag{6.20}$$

例子 1 kkt 求解优化问题:

$$\begin{aligned}
 \min \quad & \frac{1}{2} x^T p x + q^T x + r \\
 \text{Ax} &= b \\
 \because h_i(x^*) &= 0 \\
 \nabla L &= 0 \\
 \therefore Ax^* &= b \\
 Px + q + A^T v^* &= 0 \\
 \Rightarrow \begin{bmatrix} A & 0 \\ p & A^T \end{bmatrix} \begin{bmatrix} x^* \\ v^* \end{bmatrix} &= \begin{bmatrix} b \\ 0 \end{bmatrix}
 \end{aligned} \tag{6.21}$$

支持向量机 SVM

$$\begin{aligned}
 a^T x_c &> b \ \& \ a^T x_d < d \\
 a^T x_c - b &\geq t \ \& \ a^T x_d - d \leq -t
 \end{aligned} \tag{6.22}$$

在这里 a 是单位向量, 保证与原问题等价, 转化为 $|a| \leq 1$:

$$\begin{aligned}
 \min \quad & -t \\
 -a^T x_c + b &\leq -t \\
 a^T x_d - b &\leq -t \\
 -t &\leq 0 \\
 |a|^2 &\leq 1
 \end{aligned} \tag{6.23}$$

6.1.3 基础 3-数学

微积分

梯度写作列向量, Hessian matrix:

$$\begin{aligned}\nabla f(\mathbf{x}) &= \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \\ \mathbf{H}(\mathbf{x}) &= \nabla^2 f(\mathbf{x}) = \left[\frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j} \right]\end{aligned}\quad (6.24)$$

一阶导数为 0, 可能是极值点, 同时二阶导数为 0 的时候就是鞍点 saddle point, 判断鞍点可用三阶导数。矢量的泰勒级数展开

$$f(\mathbf{x}_i + \delta) \approx f(\mathbf{x}_i) + \nabla^T f(\mathbf{x}_i)\delta + \frac{1}{2}\delta^T \nabla^2 f(\mathbf{x}_i)\delta \quad (6.25)$$

为什么梯度方向是上升最快的方向, 因为泰勒公式中可以看到, 取梯度方向时, 向量共线, 夹角 0, 模最大; 同样有负梯度方向最小。通常而言, 方向更重要, 步长没有方向那么重要
把二次项也考虑进来, 就叫牛顿法

概率论部分

累积分布函数 $F(x) = P(x \leq x_0)$

概率密度函数 $f(x) = \frac{d}{dx}F(x)$ 高斯分布: 独立同分布收敛于高斯分布, 加三四项就类似高斯了

$$f(x|\mu, \sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (6.26)$$

贝叶斯公式:

$$\begin{aligned}P(A|B) &= \frac{P(A \cap B)}{P(B)} \\ P(A|B)P(B) &= P(B|A)P(A) \\ f(x|y) &= \frac{f(x, y)}{f(y)}\end{aligned}\quad (6.27)$$

贝叶斯分类, 分词, 图像识别, 邮件过滤。

6.1.4 基础 4-Regression

线性回归

目标函数 f 写成 x 带偏置的线性函数，有

$$f(\mathbf{x}) = \theta^T \mathbf{x} \quad (6.28)$$

损失函数，构造 convex 的，如

$$J = ave(\hat{\mathbf{y}} - \mathbf{y})^2 \quad (6.29)$$

梯度下降

$$\theta^{(i+1)} = \theta^{(i)} - \alpha \nabla J \quad (6.30)$$

逻辑回归

目标函数加一层阶跃函数， $sign(f)$ ，sigmoid 函数

$$\frac{1}{1 + e^{-x}} \quad (6.31)$$

损失函数，目的是对于判断错误的能很明显放大错误

$$C_{oss} = \begin{cases} -\log(\hat{\mathbf{y}}), \mathbf{y} = 1 \\ -\log(1 - \hat{\mathbf{y}}), \mathbf{y} = 0 \end{cases} \quad (6.32)$$

防止过拟合，添加权值作为正则化项

$$\begin{aligned} J &= -ave[\mathbf{y} \cdot \log(\hat{\mathbf{y}}) + 1 - \mathbf{y} \cdot \log(1 - \hat{\mathbf{y}})] + \lambda ave|\theta|^2 \\ \theta_i &= \theta_i = \alpha \frac{\partial J}{\partial \theta_j} \end{aligned} \quad (6.33)$$


多分类问题：one-vs-rest，得到每个点属于每个类的概率。损失函数如 linearSVM（可用 SGD 求解），或者交叉熵

$$\begin{aligned} L_i &= \sum_{j \neq y_i} \max[0, f(x_i, w)_j - f(x_i, w)_{y_i} + \Delta] \\ &= \sum_{j \neq y_i} \max(0, w_j^T x_i - w_{y_i}^T x_i + \Delta) \\ L &= ave(L_i) + \lambda \sum_k \sum_l \end{aligned} \quad (6.34)$$

交叉熵，指数函数保持正，归一化，指数函数为防止过大，用常数 C 做平滑：

$$L = - \sum y_i \log \frac{e^{f_{y_i}}}{\sum e^{f_{y_i}}} = - \sum y_i \log \frac{e^{f_{y_i} + C}}{\sum e^{f_{y_i} + C}} \quad (6.35)$$

vision.stanford.edu/teaching/cs231n



需要查找?? HIFT, JIST, HOG

6.1.5 基础概念

停止准则：与真值误差小于预设；两次迭代差小于预设；达到预设迭代次数

6.1.6 分类

单层感知器

单层感知器（Perceptron）解决线性可分问题，在高维空间用一个超平面划分样本。Rosenblatt 证明两类模式线性可分时算法收敛。

$$\begin{aligned} Y &= \text{sgn} \left([w_i, b] [x_i, 1]^T \right) = \text{sgn}(\mathbf{W}^T \mathbf{X}) \\ \mathbf{W}_{n+1} &= \mathbf{W}_n + \eta (\mathbf{Y}_{\text{real}} - \mathbf{Y}_n) \mathbf{X}_n \end{aligned} \quad (6.36)$$

二值化，分类的边界距离某一类很接近。常采用纠错学习规则的学习算法，把偏置作为固定输入
局限性：不能解决线性不可分问题。奇异样本训练时间长。只适合单层。

6.2 计算智能

6.2.1 遗传算法的理论和应用

6.2.2 免疫模型与算法的基本原理及其应用

6.2.3 人工神经网络的理论和应用

6.2.4 网络智能信息检索与数据挖掘

6.3 增强学习

6.4 深度学习